

ASRS triage: automatyczna klasyfikacja i analiza trendów raportów bezpieczeństwa lotniczego

Prototyp (proof of concept) do pracy magisterskiej. Repozytorium: `asrs-triage`.

1. Co robi projekt

System ASRS (Aviation Safety Reporting System) prowadzony przez NASA zbiera dobrowolne zgłoszenia od pilotów, kontrolerów, mechaników i personelu pokładowego. Każdy raport zawiera narrację w formie swobodnego tekstu, a analitycy ASRS ręcznie przypisują mu etykiety. Projekt:

1. **Klasyfikuje** narrację automatycznie, przewidując etykiety **Anomaly** analityków (może pasować kilka naraz, 53 etykiety) oraz **Primary Problem** (jedna przyczyna z 18).
2. **Porównuje** prosty model statystyczny (TF-IDF z liniowym SVM) z dostrojonym transformerem (DeBERTa-v3 z LoRA) przy identycznej ewaluacji.
3. **Analizuje trendy** w latach 2018-2021: jak często w kolejnych miesiącach pojawia się każda etykieta i każdy automatycznie znaleziony temat oraz kiedy częstość się zmienia.
4. **Udostępnia** model bazowy w lokalnej aplikacji demonstracyjnej (back end FastAPI, front end Angular).

Wszystkie stwierdzenia dotyczą **raportów otrzymanych przez ASRS**, a nie zdarzeń, które faktycznie miały miejsce. System jest dobrowolny i niezwerifikowany, więc zmiany częstości mogą odzwierciedlać zachowania zgłaszających.

2. Dane

- Źródło: eksporty CSV z ASRS Database Online. Portal ogranicza eksport do 5 000 rekordów, więc dane pobrano w przedziałach półrocznych i połączono (`scripts/load_raw.py`).
- Rozmiar po czyszczeniu: **21 633 raporty, od stycznia 2018 do grudnia 2021** (około 450 miesięcznie).
- Wejście modeli: wyłącznie tekst narracji (obie narracje zgłaszających połączone). Pola **Synopsis** i **Callback** pisane przez analityka nie są nigdy używane, ponieważ ten sam analityk przypisuje etykiety i pola te zdradzałyby odpowiedź (wyciek etykiet).
- Czyszczenie (`scripts/clean.py`): znacznik `zzz` (zanonimizowane nazwy i miejsca) zamieniany jest na `[ANON]` ; usuwane są raporty bez tekstu, etykiet lub daty oraz miesiące z mniej niż 20 raportami.
- **Podział chronologiczny** po miesiącach (`scripts/split.py`): pierwsze 70% raportów do uczenia (15 178), kolejne 15% do walidacji (3 428), ostatnie 15% do testu (3 027). Model jest zawsze testowany na raportach nowszych niż te, na których się uczył, tak jak byłby używany w praktyce. Podział losowy pozwoliłby mu uczyć się z "przyszłości".
- Etykiety Anomaly z mniej niż 30 przykładami w zbiorze uczącym są pomijane, zostaje 53.

3. Metody

Model bazowy (`scripts/baseline.py`): cechy TF-IDF (słowa i bigramy, dopasowane tylko na zbiorze uczącym) oraz liniowy SVM ze zrównoważonymi wagami klas; dla wieloetykietowego zadania Anomaly podejście one-vs-rest.

Transformer (`scripts/train_transformer.py`): DeBERTa-v3-base dostrojony metodą LoRA (trenowane są małe macierze adapterów zamiast całego modelu), jeden wspólny enkoder z dwiema głowicami (Anomaly z ważoną stratą binarną, Primary Problem z ważoną entropią krzyżową). Uczenie na darmowym GPU Kaggle przez 6 epok; próg decyzyjny dla Anomaly dobierany na zbiorze walidacyjnym.

Skracanie tekstu. Transformer czyta najwyżej 512 tokenów, a około 24% raportów testowych jest dłuższych. Przebieg 7 zachowywał pierwsze 510 tokenów (ucinał koniec). Przebieg 8 zachowuje **pierwsze 128 i ostatnie 382 tokeny** ("head+tail"), ponieważ koniec narracji często opisuje, co się stało.

Ewaluacja (`scripts/evaluate.py`): jedna wspólna funkcja dla obu modeli. Główną miarą jest **macro-F1**, czyli średnia z wyników dla poszczególnych etykiet, dzięki czemu rzadkie etykiety liczą się tak samo jak częste; raportowane są też micro-F1, strata Hamminga i F1 dla każdej etykiety.

4. Wyniki

Zbiór testowy, 3 027 raportów, podział chronologiczny:

Zadanie	Miara	TF-IDF + SVM	DeBERTa-v3 + LoRA (head)	DeBERTa-v3 + LoRA (head+tail)
Anomaly	macro-F1	0,401	0,376	0,396
Anomaly	micro-F1	0,603	0,522	0,513
Primary Problem	macro-F1	0,305	0,296	0,343
Primary Problem	micro-F1	0,639	0,602	0,626


- **Prosty model bazowy trudno pobić na tych danych.** Transformer wyraźnie przegrywał przy pierwszym sposobie skracania (przebieg 7).
- **Skracanie head+tail pomogło** (+0,020 macro-F1 dla Anomaly, +0,047 macro-F1 dla Primary Problem): model przewyższa teraz bazowy pod względem macro-F1 dla Primary Problem, mniej więcej remisuje dla Anomaly i nadal ustępuje w micro-F1. To pojedyncze przebiegi z jednym ziarnem losowym; różnice poniżej około 0,02 nie są potwierdzone.
- Przy stałym progu 0,5 model head+tail osiąga 0,425 macro-F1 dla Anomaly na zbiorze testowym. Podaję to dla przejrzystości, ale nie jako wynik główny, ponieważ próg nie został wybrany z góry (próg dobrany na walidacji daje 0,396).
- **Wiele danych bardzo pomogło:** na samym roku 2019 macro-F1 transformera dla Primary Problem wynosiło 0,216; na latach 2018-2021 jest to 0,296 (head) i 0,343 (head+tail).

Analiza błędów (`results/error_analysis.md` , przebieg 7): poprawne przypisanie wszystkich etykiet raportu zdarza się w 7,5% raportów testowych (transformer) i 12,4% (model bazowy); transformer przewiduje mniej etykiet na raport niż analitycy (2,6 wobec 3,1); trafność spada wraz z długością raportu; główne pomyłki dotyczące przyczyny to Procedure kontra Human Factors. Wiele przejranych błędów wygląda na wybór etykiet przez analityka (np. ogólne etykiety, takie jak "Published Material / Policy", dodane do raportów, które są poza tym jednoznaczne), a nie na błąd modelu.

Kalibracja (`results/calibration.json`): surowe wyniki SVM nie są prawdopodobieństwami. Skalowanie Plattą dopasowane na zbiorze walidacyjnym obniża oczekiwany błąd kalibracji (ECE) na zbiorze testowym z 0,22 do 0,016 dla Anomaly i z 0,50 do 0,019 dla Primary Problem.

5. Analiza trendów


Każdy raport został oceniony przez model, który go nie widział (5-krotna walidacja krzyżowa, losowe podziały), a następnie policzony miesięcznie według etykiety przewidzianej i, dla porównania, rzeczywistej. Punkty zmiany wyznaczono metodą PELT, tematy za pomocą BERTopic (embeddingi zdań, UMAP, HDBSCAN, 25 tematów, bez użycia etykiet).



- **Przewidywania dobrze odtwarzają prawdziwe trendy miesięczne dla etykiet specyficznych** (korelacja 0,89-0,99 dla ATC Issue, CFTT/CFIT, NMAC, Smoke/Fire) **i słabo dla ogólnych** (Clearance 0,21, FAR 0,42), gdzie analitycy etykietują niespójnie. Wnioski o trendach ograniczam do pierwszej grupy.
- **COVID-19 jest widoczny.** Liczba raportów spada do 244 w kwietniu 2020 i rośnie do 617 w lipcu 2020. Nienadzorowany temat o maskach (`mask`, `passenger`, `wearing`, `face`, `policy`) nie występuje przed lutym 2020, a w sierpniu 2020 osiąga szczyt 14,7% raportów. Żadna etykieta ASRS nie opisuje tego motywu.
- **Widoczna jest zmiana w sposobie etykietowania przez analityków.** Liczba etykiet na raport rośnie z około 2,5 do około 3,3 od początku 2021, głównie za sprawą FAR, Published Material, Clearance i Equipment Problem Critical. Prawdopodobnie odzwierciedla to praktykę analityków, a nie to, co zgłaszano, więc udziały etykiet sprzed i po tej zmianie nie są wprost porównywalne. Nie znalazłem dokumentacji tej zmiany; to hipoteza.
- Kilka skoków (ATC Issue i Weather w kwietniu 2019, Equipment Less Severe w lutym 2020, NMAC w maju 2021) nie ma przyczyny, którą udało mi się zidentyfikować.

Kontrola wycieku danych. Podział na zbiór uczący, walidacyjny i testowy jest chronologiczny (uczący 2018-01 do 2020-08, walidacyjny 2020-09 do 2021-04, testowy 2021-05 do 2021-12), bez wspólnych miesięcy, numerów raportów (ACN) ani identycznych tekstów. Ponieważ wykresy trendów korzystają z losowych podziałów, porównanie powtórzono ściśle w czasie (`scripts/leakage_check.py`): mediana korelacji 0,68 wobec 0,67 i około 30% większe błędy miesięcznych udziałów. Analiza tematów w ogóle nie używa etykiet.

Topics with the largest change between 2018 and 2021 (orange: spring 2020)



6. Aplikacja demonstracyjna

Interfejs aplikacji jest w języku angielskim.

ASRS triage

Paste an aviation safety report narrative and see which event types and which underlying cause the model assigns to it.

Classify a report

Trends 2018-2021

Report narrative

During climbout through 8,000 feet the cabin crew reported a strong electrical burning smell in the aft galley. A flight attendant found a galley oven emitting light smoke. The Captain declared an emergency and we followed the smoke and fumes checklist, removing power from the galley bus. The smell dissipated within several minutes. We returned to the departure airport and landed uneventfully with fire crews standing by. Maintenance later found a failed heating element.

Try an example:

Altitude deviation

Smoke in the cabin

Runway excursion

Classify report

Event type (Anomaly, several can apply)

Flight Deck / Cabin / Aircraft
Event Smoke / Fire / Fumes /
Odor

predicted 100%

because of: smoke, smell, fumes, burning, fire

Aircraft Equipment Problem
Less Severe

predicted 70%

because of: smoke, maintenance, smell, oven, departure
airport

Aircraft Equipment Problem Critical

13%

because of: fire, electrical, power, failed, emergency

Flight Deck / Cabin / Aircraft Event Illness /
Injury

1%

because of: smell, flight attendant, the aft, fumes, galley

Deviation / Discrepancy - Procedural
Security

0%

because of: galley, attendant found, bus, flight attendant,
smell dissipated

Likely cause (Primary problem, one applies)

Aircraft

predicted 100%

because of: smell, smoke, electrical, fumes, failed

Software and Automation

0%

because of: 000, from the, by, with, an

Staffing

0%

because of: galley, emergency and, several, an emergency,
the departure

Most similar past reports (by wording, from 21,633 ASRS reports)

ACN 1697269 2019-10 similarity 18%

Cabin crew reported burning smell in back of cabin. [identified as an] emergency. Landed at [ANON]....

Flight Deck / Cabin / Aircraft Event Smoke / Fire / Fumes / Odor cause: Aircraft

ACN 1800152 2021-04 similarity 17%

Just prior to leveling off at FL340; Flight Attendant called and stated there was an electrical burning smell in the forward galley. There was not any smoke nor fire; just an odor. We notified ATC; turned back toward [ANON]; accomplished all checklist items; and landed uneventfully. After clearing the runway; we had th...

Aircraft Equipment Problem Less Severe Flight Deck / Cabin / Aircraft Event Smoke / Fire / Fumes / Odor cause: Aircraft

ACN 1537277 2018-04 similarity 15%

On climbout we started to smell electrical burning or like an oven being cleaned. About that time the cabin crew called up and said that they smelled an electrical burning. Captain asked if the oven was on and they replied no. At this point we [advised ATC] and started to turn back towards [departure airport]. The Capt...

Aircraft Equipment Problem Less Severe Flight Deck / Cabin / Aircraft Event Smoke / Fire / Fumes / Odor cause: Aircraft

Model: tfidf-linear-svc-baseline. Percentages are probabilities calibrated on held-out validation reports; a label can be marked "predicted" at a low percentage because the model is tuned to catch rare labels. For the cause, the first row is the model's decision; its percentage can be lower than another cause's because calibrated probabilities favour common causes. "Because of" lists the words in your text that raised the score. ASRS reports are self-reported and unverified, so results describe reports, not confirmed incidents. Research demo, not for operational use.

Po wklejeniu raportu (lub użyciu przycisku z przykładem) aplikacja pokazuje:



- najbardziej prawdopodobne **typy zdarzeń** oraz **przyczynę** jako skalibrowane prawdopodobieństwa;
- **"because of"**: słowa z tekstu, które podniosły wynik danej etykiety (na podstawie wag modelu liniowego);
- **trzy najbardziej podobne wcześniejsze raporty** spośród 21 633, wraz z ich etykietami.

Strona **Trends** pokazuje miesięczny udział dowolnej etykiety (etykiety analityków obok przewidywań modelu, wykryte punkty zmiany, zaznaczony okres COVID), tematy nienadzorowane, liczbę raportów oraz liczbę etykiet na raport.

ASRS triage

Paste an aviation safety report narrative and see which event types and which underlying cause the model assigns to it.

Classify a report Trends 2018-2021



Out-of-fold predictions on 21,633 reports, January 2018 to December 2021. The counts describe reports received by ASRS, not incidents.



Uwagi: przyczyna pokazana jako pierwsza jest decyzją samego modelu, która może mieć niższy procent niż inna przyczyna, ponieważ skalibrowane prawdopodobieństwa faworyzują klasy częste (użycie ich do decyzji obniżyłoby macro-F1 dla przyczyny z 0,305 do 0,266). Demo używa modelu bazowego, który jest szybki i działa bez GPU.

7. Jak to jest zbudowane

Część	Technologia
Dane i model bazowy	Python 3.12, pandas, scikit-learn
Transformer	PyTorch, Hugging Face Transformers, PEFT (LoRA), uczenie na GPU Kaggle
Trendy i tematy	ruptures (punkty zmiany), BERTopic, sentence-transformers
API	FastAPI (/predict , /trends/labels , /trends/topics)
Front end	Angular 22, komponenty standalone, sygnały, własne wykresy SVG
Testy	Vitest (5 testów front endu)

Struktura repozytorium i instrukcja uruchomienia są w `README.md` . W skrócie:

```
pip install -r requirements.txt
python scripts/load_raw.py && python scripts/clean.py && python scripts/split.py
```

```
python scripts/baseline.py
python scripts/trends.py && python scripts/topics.py
python scripts/export_baseline.py
./run_demo.sh          # API na :8000, aplikacja na :4200
```

Przebieg prac jest zapisany w historii Gita (komunikaty w konwencji Conventional Commits). Decyzje projektowe (podział chronologiczny, wykluczenie pola Synopsis, protokół porównania) i interpretacja wyników są opisane powyżej.

8. Ograniczenia

- Tylko cztery lata i około 21,6 tys. raportów (plan zakładał 30 tys. lub więcej); cztery lata nie pozwalają odróżnić sezonowości od trendu.
- Pojedyncze przebiegi uczenia, jedno ziarno losowe; dotąd jedna ablacja (skręcanie tekstu).
- Przewidywania w analizie trendów pochodzą z walidacji krzyżowej z losowymi podziałami. Sprawdzenie ściśle w czasie (uczenie na wcześniejszych latach, predykcja 2019, 2020, 2021) dało takie samo odwzorowanie trendów (mediana korelacji 0,68 wobec 0,67), ale o około 30% większe błędy miesięcznych udziałów, więc poziomy są mniej dokładne, niż sugerują wykresy; kształty trendów nie wynikają z wycieku danych.
- Zmiana w etykietowaniu w 2021 ogranicza porównywanie udziałów etykiet ponad nią.
- Kalibracja w demie jest dopasowana na jednym podziale z jednego okresu.

9. Dalsze kroki

- Ulepszenie transformera: kolejne ablacje (maksymalna długość, learning rate, wagi klas), model o dłuższym kontekście, kilka ziaren losowych.
- Więcej danych (od 2022), aby osiągnąć planowany rozmiar i sprawdzić, czy zmiana w etykietowaniu się utrzymuje.
- Możliwe rozszerzenie, jeśli starczy czasu: transkrypcja rozmów radiowych kontroli ruchu lotniczego i klasyfikacja transkryptów wytrenowanym modelem.